

УДК 004.8

Разработка сервиса аудита использования генеративных языковых моделей для профессиональных текстов

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

LLM — большие языковые модели (Large Language Models)

NLP — обработка естественного языка (Natural Language Processing)

ML — машинное обучение (Machine Learning)

AI — искусственный интеллект (Artificial Intelligence)

API — программный интерфейс приложения (Application Programming Interface)

JSON — формат обмена данными (JavaScript Object Notation)

PDF — переносимый формат документов (Portable Document Format)

OCR — оптическое распознавание символов (Optical Character Recognition)

ROC — кривая ошибок классификации (Receiver Operating Characteristic)

РЕФЕРАТ

Отчёт по НИР: 52 с., 12 рис., 4 табл., 22 источников.

КЛЮЧЕВЫЕ СЛОВА: генеративные языковые модели, анализ текста, перплексия, стилометрия, машинное обучение, логистическая регрессия, аудит текстов.

Объектом исследования являются тексты профессионального назначения, включая студенческие работы и иные формализованные текстовые документы.

Предметом исследования являются методы и алгоритмы определения использования генеративных языковых моделей при создании текстов на основе статистических и стилометрических признаков.

Цель работы — разработка сервиса аудита текстов, позволяющего оценивать вероятность использования генеративных языковых моделей при их создании.

В ходе работы проводились:

1. Анализ существующих подходов к детекции текстов, сгенерированных LLM;
2. Формализация набора статистических и стилометрических метрик;
3. Разработка алгоритма оценки вероятности использования LLM;
4. Реализация программного прототипа сервиса анализа текстов;
5. Экспериментальная проверка эффективности предложенного подхода.

В результате исследования разработан программный прототип сервиса аудита текстов, реализующий вычисление набора метрик и формирование вероятностной оценки использования генеративных языковых моделей.

Степень внедрения: разработанный прототип находится на стадии экспериментальной реализации и может быть использован в учебных и исследовательских целях.

Эффективность: предложенный подход позволяет выявлять признаки использования генеративных языковых моделей в текстах и может быть применён для предварительного анализа текстовых документов.