

Раздаточный материал к выпускной квалификационной работе

Тема: Разработка сервиса аудита использования генеративных языковых моделей для профессиональных текстов
Обучающийся: Пальчук Герман Андреевич
Научный руководитель: канд. физ.-мат. наук, доц. Власов Дмитрий Викторович
Санкт-Петербург, 2026

Выпускная квалификационная работа

Разработка сервиса аудита использования генеративных языковых моделей для профессиональных текстов

Раздаточный материал подготовлен для сопровождения доклада на защите выпускной квалификационной работы. Он содержит ключевые положения исследования, краткое описание разработанного программного продукта, результаты экспериментальной оценки модели и основные выводы.

Краткая характеристика работы

Показатель	Значение
Область исследования	Детекция текстов, созданных с использованием генеративных языковых моделей
Тип разработанного решения	Веб-сервис аудита текста
Основной стек	Python, FastAPI, Jinja2, SQLAlchemy, SQLite, CatBoost
Основной результат	Прототип сервиса, рассчитывающий P(LLM), метрики текста и диагностические признаки
Экспериментальная база	Корпус из 997 текстов: 414 human и 583 LLM
Ключевая метрика модели	ROC-AUC 0,9745 на тестовом фолде

Введение

Актуальность темы

Генеративные языковые модели позволяют создавать связные и стилистически корректные тексты, которые во многих случаях трудно отличить от текстов, написанных человеком. Это создает риски для образовательной и профессиональной среды: возникают вопросы авторства, самостоятельности выполнения работ, достоверности документов и корректности экспертной оценки.

Существующие детекторы LLM-текстов имеют ограничения. Они могут быть чувствительны к жанру, языку, способу генерации, последующему редактированию и формализованному стилю профессиональных текстов. Поэтому в работе задача рассматривается не как вынесение окончательного вердикта, а как аудит: система должна предоставить вероятностную оценку и набор интерпретируемых признаков для принятия экспертного решения.

Объект и предмет исследования

Элемент	Формулировка
Объект исследования	Процесс автоматизированного анализа и выявления машинно-сгенерированных текстов в профессиональной среде
Предмет исследования	Статистические и стилометрические признаки текстов, а также методы их агрегации и классификации для оценки вероятности использования генеративных языковых моделей

Цель работы

Разработать и теоретически обосновать прототип сервиса аудита использования генеративных языковых моделей при создании профессиональных текстов.

Задачи исследования

1. Провести обзор и систематизацию существующих методов детекции текстов, сгенерированных языковыми моделями.
2. Выделить ключевые признаки и метрики, применимые для анализа профессиональных жанров.
3. Спроектировать архитектуру сервиса аудита: компоненты, обмен данными, интерфейсы и хранение результатов.
4. Реализовать алгоритмы извлечения текста, нормализации, расчета признаков и формирования отчета.
5. Провести экспериментальную оценку модели на сформированном корпусе профессиональных текстов.
6. Сформулировать рекомендации по интерпретации вероятностных оценок и дальнейшему развитию сервиса.

Методы исследования

Метод	Использование в работе
Анализ научных и прикладных источников	Систематизация подходов к детекции LLM-текстов
Статистический анализ текста	Расчет количественных характеристик документов
Стилометрический анализ	Анализ структуры, разнообразия и повторяемости текста
Машинное обучение	Обучение CatBoost-классификатора для оценки P(LLM)
Экспериментальная проверка	Оценка качества по ROC-AUC, accuracy, precision, recall и F1-score
Инженерное проектирование	Разработка архитектуры веб-сервиса, API, БД и интерфейса

Основные теоретические положения

Подходы к детекции LLM-текстов

Подход	Суть	Ограничения
Перплексия и вероятностные характеристики	Оценка предсказуемости текста языковой моделью	Высокая вычислительная стоимость, зависимость от выбранной модели
Статистические признаки	Анализ длины слов, предложений, пунктуации, энтропии	Отдельные признаки недостаточны для надежного вывода
Стилометрические признаки	Анализ авторского и жанрового стиля	Чувствительность к жанру и редактированию
Машинное обучение	Объединение нескольких признаков в единую модель классификации	Требуется размеченный корпус и контроль утечек данных
Артефакты генерации и форматирования	Поиск скрытых Unicode-символов, экранирований и технических следов	Являются диагностическими сигналами, а не самостоятельным доказательством

Выбранный подход

В работе выбран гибридный подход: сервис объединяет расчет статистических и стилометрических признаков, диагностический анализ Unicode-сигналов и модель машинного обучения. Такой подход позволяет получить не только итоговую оценку P(LLM), но и объяснимые показатели, которые могут быть использованы экспертом при интерпретации результата.

Что означает P(LLM)

P(LLM) — это модельная оценка вероятности принадлежности текста к классу LLM. Она не является абсолютным доказательством происхождения текста. Корректная интерпретация должна учитывать:

- значение вероятности;
- распределение отдельных метрик;
- наличие технических и Unicode-индикаторов;
- жанр и контекст документа;
- возможное последующее редактирование текста человеком.

Признаки, используемые моделью

Признак	Интерпретация
<code>lexical_diversity</code>	Лексическое разнообразие текста
<code>burstiness</code>	Неравномерность длин предложений
<code>average_sentence_length</code>	Средняя длина предложения
<code>text_entropy</code>	Энтропия текста
<code>stop_word_ratio</code>	Доля стоп-слов
<code>word_length_variation</code>	Вариативность длины слов
<code>punctuation_ratio</code>	Доля пунктуации
<code>repetition_score</code>	Повторяемость фрагментов

Unicode-индикаторы и перплексия сохранены как диагностические признаки сервиса, но не включены в основной входной вектор CatBoost-модели.

Анализ объекта исследования


Разработанный объект исследования

В практической части разработан веб-сервис аудита текста. Он принимает текст или документ, извлекает содержимое, рассчитывает признаки, применяет модель машинного обучения, сохраняет результат и формирует отчет для пользователя.

Архитектура сервиса

Компонент	Назначение
FastAPI	REST API и серверная часть приложения
Jinja2	HTML-интерфейс демонстрационного сервиса
SQLModel и SQLite	Работа с пользователями, проверками, отчетами и экспертными оценками
ingestion	Извлечение текста из PDF, DOCX, RTF, ODT и TXT
preprocessing	Очистка и базовая нормализация текста
metrics	Расчет статистических, стилометрических и технических признаков
scoring	Интеграция CatBoost и расчет P(LLM)
report_builder	Формирование структурированного отчета

Пайплайн обработки



Хранение данных

Таблица	Назначение
users	Пользователи, роли и данные профиля
audit_checks	История проверок, значение P(LLM), имя файла и полный JSON-отчет
teacher_audit_feedback	Экспертная оценка преподавателя по сохраненной проверке

Особенность таблицы `teacher_audit_feedback` заключается в сохранении снимка части результата на момент экспертной оценки. Это фиксирует контекст решения преподавателя и позволяет анализировать качество модели даже при последующем развитии сервиса.

Основные API-маршруты

Маршрут	Назначение
POST /extract	Извлечение текста из файла
POST /audit	Запуск аудита и сохранение результата
GET /report/{id}	Просмотр сохраненного отчета
GET /history	Просмотр истории проверок
POST /api/teacher-feedback	Сохранение экспертной оценки преподавателя

Экспериментальная оценка и рекомендации

Исследовательский корпус

Показатель	Значение
Всего объектов	997
Human-тексты	414
LLM-тексты	583
Тип задачи	Бинарная классификация
Разбиение данных	Grouped Stratified K-Fold
Группировка	По work_id, чтобы связанные тексты не попадали одновременно в обучение и проверку

Конфигурация основной модели

Параметр	Значение
Модель	CatBoostClassifier
Количество итераций	800
Learning rate	0,05
Depth	6
Loss function	Logloss
Eval metric	AUC
Early stopping	50 итераций

Результаты на тестовом фолде

Метрика	Значение
ROC-AUC	0,9745
Accuracy	0,8950
Верных классификаций	179 из 200
Верно распознанных human-текстов	73
Верно распознанных LLM-текстов	106
Ложноположительных решений	10
Ложноотрицательных решений	11

Результаты кросс-валидации

Метрика	Значение
ROC-AUC	0,9759 ± 0,0054
Accuracy	0,9218
F1 macro	0,9192

Предложения и рекомендации

1. Использовать результат сервиса как инструмент поддержки экспертного решения, а не как автоматический вердикт.
2. В отчетах явно указывать, что P(LLM) является модельной вероятностной оценкой.
3. При высокой P(LLM) анализировать не только итоговое число, но и отдельные метрики, Unicode-сигналы и контекст документа.
4. Сохранять экспертную обратную связь преподавателей для последующего анализа ошибок модели.
5. Расширять корпус текстов новыми профессиональными жанрами и примерами частично отредактированных LLM-текстов.
6. Для промышленного внедрения перейти от SQLite к серверной СУБД, добавить мониторинг качества модели и механизмы аудита доступа.
7. Проводить периодическую переоценку модели, поскольку стиль генерации языковых моделей меняется с развитием технологий.

Заключение и выводы

Основные результаты работы

В ходе выполнения ВКР получены следующие результаты:

- 1. Проведен анализ существующих подходов к детекции текстов, созданных с использованием генеративных языковых моделей.
- 2. Обоснован выбор гибридного подхода, объединяющего статистические, стилометрические и диагностические признаки.
- 3. Спроектирована архитектура веб-сервиса аудита текста.
- 4. Реализован программный прототип на Python с использованием FastAPI, SQLAlchemy, SQLite и CatBoost.
- 5. Поддержаны пользовательские сценарии загрузки документа, запуска аудита, просмотра отчета, истории проверок и экспертной оценки преподавателя.
- 6. Сформирован исследовательский корпус из 997 объектов.
- 7. Обучена и проверена CatBoost-модель, достигшая ROC-AUC 0,9745 на тестовом фолде.
- 8. Сформулированы рекомендации по интерпретации P(LLM) и дальнейшему развитию сервиса.

Практическая значимость

Разработанный сервис может применяться как прототип инструмента поддержки проверки профессиональных и учебных текстов. Он помогает быстро получить набор метрик, зафиксировать результат анализа, сохранить отчет и собрать экспертную обратную связь. При этом сервис не заменяет преподавателя или эксперта, а предоставляет данные для более обоснованного решения.

Ограничения работы

Ограничение	Комментарий
Вероятностный характер результата	P(LLM) требует экспертной интерпретации
Зависимость от корпуса	Модель обучена и проверена на конкретном наборе текстов
Влияние редактирования	Сильная ручная переработка LLM-текста может снижать различимость
Прототипный уровень системы	SQLite и монолитная архитектура подходят для исследования и демонстрации, но требуют развития для промышленного внедрения

Итоговый вывод

Цель выпускной квалификационной работы достигнута. Разработан и экспериментально проверен прототип сервиса аудита использования генеративных языковых моделей для профессиональных текстов. Сервис реализует полный цикл обработки: от извлечения текста и расчета признаков до

получения P(LLM), сохранения отчета и фиксации экспертной оценки. Экспериментальная оценка подтвердила высокую разделяющую способность выбранного подхода, а предложенная архитектура может быть использована как основа для дальнейшего развития системы.